

中文垂直领域检索增强方法的系统对比研究： 上下文检索、知识图谱与重排序在水利防洪预案中的 实证分析

摘要

面向水利防洪预案等结构化公文在应急场景中的条款定位与知识查询需求，本文构建并评测了“基线检索—上下文增强检索（Contextual Retrieval, CR）—Cross-Encoder 重排序”的检索式问答流程。针对中文垂直语料与本地小模型生成上下文可能引入噪声的问题，本文设计了 2×2 消融实验（Baseline/CR × 无/有重排序），并在真实防洪预案语料与问题集（n=30）上进行对比。实验结果表明：在无重排序条件下，CR 相对 Baseline 显示有限改进（检索准确率由基线的 76.7% 提升至 80.0%， $p < 0.001$ ），但改进不均衡——数值查询提升 10%，实体和流程查询无改进，反映小模型上下文生成的质量与查询类型密切相关；引入 Cross-Encoder 重排序后，Baseline 与 CR 均提升至 96.7%，两者无差异（ $p = 0.988$ ），表明重排序可有效纠正粗排误差并消除不同预排策略的差异性。与此同时，知识图谱路线在无领域标注与严格 Schema 约束条件下呈现“高分假象”，实际相关性不足。研究结果给出结构化水利公文场景下 CR 的适用边界与重排序的关键作用，为水利行业构建低成本、高可靠的检索式问答系统提供工程参考。

关键词：检索增强生成（RAG）；上下文检索（CR）；水利防洪预案；消融实验；Cross-Encoder 重排序；水利信息化

1. 引言

水利防洪预案是应急管理的关键文件，涵盖响应级别、处置流程、物资保障与职责分工等关键信息。汛期应急场景中，工作人员需要在极短时间内定位特定条款——如"IV级险情应在多少小时内上报""防汛物资储备标准是多少"等。传统的关键词搜索依赖精确匹配，面对水利术语的专业性与文档的复杂层级结构（章-节-条款嵌套、表格密集），往往检索效果不理想。近年来，检索增强生成（Retrieval-Augmented Generation, RAG）技术为文档智能问答提供了新思路：先通过向量检索与关键词检索定位相关段落，再由大语言模型生成自然语言答案。然而，标准 RAG 在中文垂直领域仍面临语义歧义（如"险情等级"与"响应级别"混淆）与上下文丢失（分块后关键信息与所属章节脱离）两大挑战。

围绕上述问题，当前主流的检索增强方法包括三条技术路线：一是上下文增强检索（Contextual Retrieval, CR），由 Anthropic 提出，通过大语言模型为每个文本块生成上下文前缀来缓解分块后的信息丢失；二是知识图谱（Knowledge Graph, KG），从文档中抽取实体-关系三元组并通过图推理回答问题；三是 Cross-Encoder 重排序，使用查询-文档联合编码模型对粗排结果进行精排。Anthropic 报告显示 CR 在英文数据集上可降低 49% 的检索失败率，但该结果依赖 Claude 等大参数模型，且在中文垂直领域尚无系统验证。知识图谱虽然理论上可支持多跳推理，但通用大语言模型在垂直领域的实体抽取能力有限。重排序已在信息检索领域被广泛证实有效，但其与 CR 的配合效果尚不明确。

本文以某市水利防洪预案及标准化管理手册为核心语料，选取包括《杨家横水库调度规程》《常庄水库防洪预案》在内的 6 份核心政策文件，共计 22.8 万字。经去噪与结构化清洗，构建了包含 1080 个语义切片的垂直领域知识库。本文设计了 30 个覆盖数值、实体、流程三类查询的测试问题集，系统对比上述三种增

强方法的实际效果。通过 2×2 消融实验（Baseline/CR × 无/有重排序）与统计检验，本文揭示了三个关键发现：（1）CR 在本地小模型条件下改进有限且不均匀，整体准确率改进 3.3%，但数值查询提升 10%，实体和流程查询无改进；（2）Cross-Encoder 重排序可完全消除这一不均匀性，使各方法均恢复至 96.7% 准确率；（3）知识图谱在无人工标注条件下呈现"高分假象"，实用性不足。基于实验结果，本文给出水利行业低成本检索问答系统的部署建议。

2. 问题定义与研究框架

水利防洪预案的智能问答可形式化为：给定用户查询 q （自然语言问题）和文档集合 $D = \{d_1, d_2, \dots, d_N\}$ ，系统需从 D 的文本块 $C = \{c_1, c_2, \dots, c_M\}$ 中检索出与 q 最相关的 Top- k 个块，再由大语言模型基于检索结果生成答案 a 。核心挑战在于检索阶段的准确性——若 Top- k 中未包含正确信息，后续问答必然失败。

本文的研究框架围绕"粗排 → 增强 → 精排"三阶段展开。粗排阶段采用向量检索与 BM25 的混合融合作为基线；增强阶段分别考察 CR（上下文前缀增强）与 KG（知识图谱检索）两种策略；精排阶段引入 Cross-Encoder 重排序。为厘清各组件的独立作用与协同效应，本文设计了 2×2 消融实验（表1），其中 Baseline/CR 为分块策略变量，无/有重排序为精排变量。此外，KG 方法因效果不佳（详见 3.3 节与 4.1 节），作为参照基线报告，不纳入消融矩阵。

表1 消融实验设计矩阵

	无重排序	有重排序
基线分块	Baseline	Baseline + Reranker
CR 增强分块	CR	CR + Reranker

全部实验在相同硬件（AMD Ryzen 7 8845H 处理器（8 cores），32 GB DDR5 内存，NVIDIA RTX 4060 Laptop GPU（8 GB））、相同测试集（30 题固定

顺序)与相同问答模型(Gemma3:12B)下进行,确保对比的公平性。系统采用本地化部署(Ollama),无需商用API,满足水利行业数据安全与内网部署的合规要求。

3. 实验设计与实证分析

3.1 基线混合检索系统

基线系统采用向量检索与 BM25 的混合融合策略。向量检索基于 BAAI/bge-small-zh-v1.5 嵌入模型,该模型针对中文语义相似度任务进行优化。本文以 6 篇防洪预案相关规范性文件为数据源,总字数约 23 万字。经预处理后按 512 token 分块(重叠 50 token),生成 1080 个文本块,并保留文件名、页码与章节标题作为元数据,存储于 ChromaDB 向量数据库。

BM25 检索采用 Jieba 分词,并扩展水利领域自定义词典(如“防汛”“应急响应”“险情等级”等),以提升专业术语的匹配效果。两路检索结果通过 Reciprocal Rank Fusion (RRF) 进行融合:

$$score(c) = \left(\sum_{r=\{v,b\}} \frac{1}{k + rank_r(c)} \right), \quad k = 60$$

其中 $rank_v$ 与 $rank_b$ 分别表示向量与 BM25 的排名, k 为平滑参数。融合后选取得分最高的 Top-5 文本块作为最终检索结果。

测试集共 30 个问题,由水利专业人员编写,涵盖三类查询:数值查询($n=10$)、实体查询($n=10$)与流程查询($n=10$)。评价指标包括 Top-5 命中率与人工标注准确率(1.0 完全正确,0.5 部分正确,0.0 错误)。

3.2 上下文增强检索方法

上下文增强检索（Contextual Retrieval, CR）的核心思想是为每个文本块 c_i 生成一段简要上下文描述 ctx_i ，使其在脱离原始文档结构后仍保留必要的语境信息。增强后的文本块定义为：

$$c_i' = ctx_i \oplus c_i$$

其中 $\oplus$ 表示字符串拼接操作。

上下文生成采用本地部署的 Gemma 3:12B 模型（Ollama），生成完成后，基于增强文本块重新构建向量嵌入与 BM25 索引，检索流程与基线保持一致。

需要指出的是，在本地模型条件下，CR 可能产生以下三类副作用：

1. **信息压缩效应**：对列表型或数值型内容进行过度概括，导致细节丢失；
2. **语义泛化效应**：生成过于宏观的章节描述，降低区分度；
3. **噪声引入效应**：对复杂结构（如表格）理解偏差，生成误导性前缀。

上述因素可能削弱检索精度，具体影响将在第 4 节实验中进行量化分析。

3.3 知识图谱构建与检索

知识图谱路线旨在从文档中抽取结构化三元组（实体 - 关系 - 实体），并通过图结构进行推理检索。本文采用 OneKE-13B 模型进行实体与关系抽取，结合 OpenKG 防洪领域 Schema，定义组织、人员、设备、级别、时限与流程六类实体，以及“隶属于”“负责”“触发”“执行”“上报至”五类关系。抽取结果通过 LlamaIndex 的 KnowledgeGraphIndex 构建图谱索引。

初步实验（选取 10 个代表性问题）显示，在无人工标注与领域微调的条件下，该方法存在明显瓶颈：

（1）在 1080 个文本块中共抽取 417 条三元组，平均每块约 0.39 条。经人工筛查，其中约 50.8% 为无效或噪声三元组（如 PDF 元数据、格式符号及测试残留内容），最终有效三元组仅 205 条，平均每块约 0.19 条。抽取结果呈现出明显的稀疏性。进一步分析发现，数值型约束信息（如时限、数量与标准）在有效三元组

中的覆盖率较低，部分关键业务约束未被结构化表示。该现象表明，在未进行领域微调与规则约束的情况下，通用抽取模型在水利垂直文本上的结构化能力存在明显瓶颈；

（2）关系表达粒度偏粗，例如仅抽取“组织 - 负责 - 防汛”等通用关系，难以表达“上报时限为 2 小时”等精细语义；

（3）LlamaIndex 框架在节点评分机制上存在与实际语义相关性不完全一致的情况，导致排序结果与真实需求存在偏差。

综合考虑抽取稳定性与工程复杂度，本文将知识图谱方法作为参照实验报告（见第 4.1 节），但不纳入 2×2 消融矩阵，重点分析 CR 与重排序机制的性能差异。

3.4 重排序与消融实验设计

在粗排返回 Top-100 候选块后，采用 BAAI/bge-reranker-base 进行精排。该模型为 Cross-Encoder 架构，与双塔向量模型不同，其将查询与候选文本拼接为统一输入：

$$S_{rerank}(q, c) = f_{CE}([q; c])$$

- 其中 f_{CE} 表示 Cross-Encoder 模型， $[q; c]$ 表示查询与候选文本的拼接输入。

模型对每个候选块独立打分，按得分降序取 Top-5 作为最终结果。该模型在 2 亿中文查询-文档对上训练，基于 BERT-base-chinese 架构（1.1 亿参数），推理时对 100 个候选块逐一编码，在 AMD Ryzen 7 8845H（CPU）环境下，对粗排 Top-100 候选块使用 bge-reranker-base 重排序，单次查询平均额外耗时 2.44 s（基于 10 个随机问题的测量；详见 reranker_cost_analysis.json）。考虑不同问题与系统负载波动，本文将该开销表述为“约 2 - 3 s”。

消融实验按表 1 设计，四组配置共享相同的测试集、问答模型与硬件环境。为验证结果稳定性，Phase 3 实验重复执行 3 次，报告均值与标准差。统计显著性检验采用配对 t 检验 ($\alpha = 0.05$) 与符号检验（非参数验证），同时计算 Cohen's d 作为效应量指标。

4. 实验结果与讨论

4.1 整体性能对比

表 2 展示了四组消融配置与 KG 参照基线在全部 30 个测试问题上的表现。

表 2 主要实验结果 (n = 30)

方法	准确率	正确数/总数	平均得分	标准差	检索链路耗时
Baseline	76.7%	23/30	0.5145	0.0491	~0.03 s (29 ms)
CR	80.0%	24/30	0.5188	0.0488	~0.02 s (24 ms)
Baseline + Reranker	96.7%*	29/30	0.9552	0.1554	~2.47 s (0.03s + 2.44s)
CR + Reranker	96.7%*	29/30	0.9580	0.1544	~2.46 s (0.02s + 2.44s)
KG (参照)	30.0%	3/10*	1000.0**	—	无可靠数据

*注：Baseline 和 CR 的数据源自增强实验 (phase3_enhanced_data.json)，以 keyword_hit_rate 为评判标准。Baseline+Reranker 和 CR+Reranker 的数据源自消融实验 (phase3_reranker_ablation_data.json)，因实验流程与数据评估的轻微差异，为保持分析严谨性，第 4.2 节仅对比 Baseline vs CR；Reranker 角度的结论见第 4.1 节与 4.3 节。KG 仅在 10 个代表性问题上测试。

**KG 得分为 LlamaIndex 框架默认值，不代表真实相关性。

- 该结果基于固定 30 题测试集，未进行随机抽样扩展，结果可能存在数据依赖性。

实验结果呈现三个核心发现：

CR 的差异化表现。

在无重排序条件下，CR 相较 Baseline 呈现有限但统计显著的提升 (76.7% →

80.0%， $p < 0.001$ ）。然而，该整体增益在不同查询类型上表现不均：数值查询提升 10 个百分点（80% → 90%），实体查询与流程查询则未观察到改进（分别为 70% 与 80%）。

进一步分析发现，数值型答案结构简洁（如“2 小时”），上下文前缀对其影响较小；而实体与流程类问题往往涉及完整列表或多条件约束，小模型生成的上下文容易产生概括或泛化，削弱原始细节表达，从而影响召回质量。说明小模型驱动的上下文增强在复杂结构型内容上存在能力边界。

重排序的纠正作用。

引入 Cross-Encoder 后，Baseline + Reranker 与 CR + Reranker 均提升至 96.7%，差异不再显著。以“水库超汛限水位后如何处置？”为例，粗排阶段正确文本块位于第 2 位（0.76），重排后跃升至第 1 位（0.95）。Cross-Encoder 通过联合建模查询与候选文本，能够捕捉“超汛限水位”与“开闸泄洪”等语义关联，而双塔模型仅基于浅层词汇相似度进行匹配。整体上，重排序将平均相关性得分由 0.51 提升至 0.96，显著增强排序可靠性。

知识图谱的“高分假象”。

KG 方法在 LlamaIndex 框架下获得 1000.0 的默认评分，但实际准确率仅 30%。例如，在“多少小时内需要上报？”这一问题中，图谱返回泛化性陈述，而关键数值“2 小时”未被抽取为结构化实体。此外，其平均响应时间为 23.5 s，明显高于其他方法。结果表明，在缺乏人工标注与领域适配的条件下，通用抽取模型难以支撑高质量结构化检索。

4.2 不同查询类型分析

表 3 按问题类别展示了无重排序条件下 Baseline 与 CR 的准确率对比。为避免评估标准差异带来的干扰，重排序结果未纳入本表，详见 4.1 与 4.3 节。

表 3 不同问题类型的准确率

类别	Baseline	CR
A 类-数值查询 (n = 10)	80%	90%
B 类-实体查询 (n = 10)	70%	70%
C 类-流程查询 (n = 10)	80%	80%

从分类结果可见，CR 的改进呈现明显的不均匀性：数值查询提升 10 个百分点，而实体与流程类查询未观察到增益。

结合 3.2 节分析，数值类问题通常答案结构简洁、信息密度集中，上下文前缀对原始文本干扰较小；而实体与流程类问题往往涉及列表结构或多条件限定，小模型生成的上下文容易产生概括或语义泛化，从而削弱原始细节信息，影响召回质量。

这一结果表明，上下文增强在结构简单的问题上具有一定辅助作用，但在复杂结构型查询中，其效果受限于生成质量。

4.3 统计显著性与稳定性分析

表 4 报告核心对比的统计检验结果。

表 4 统计检验结果

对比	检验方法	统计量	p 值	效应量	结论
Baseline vs CR	配对 t 检验	t = 5.012	< 0.001	d = 0.92	CR 显著提升检索得分
Baseline vs CR	符号检验	胜 19 / 平 11 / 负 0	0.002	—	性能改进方向一致
B+R vs CR+R	配对 t 检验	t = 0.015	0.988	d ≈ 0	重排序消除差异
Baseline vs B+R	配对 t 检验	t = 18.3	< 0.001	d = 3.34	重排序显著提升得分

注：配对 t 检验基于检索结果的余弦相似度得分计算；“胜”指 CR 得分高于 Baseline 的次数。

Baseline 与 CR 的检索相似度差异在统计上高度显著 ($p < 0.001$)，效应量 $d=0.92$ 属于大效应。符号检验进一步确认了这一趋势：在 30 个测试问题中，CR 的检索得分在 19 个问题上优于 Baseline（胜 19 / 平 11 / 负 0），表明 CR 带来的上下文增强效应具有系统性，而非随机波动。

深入分析发现，这种改进具有明显的不均匀性：主要收益来自数值查询类问题（如“汛限水位”），CR 生成的上下文成功关联了孤立的数值与实体；而在实体和流程类查询中，两者表现接近。然而，引入重排序后，B+R 与 CR+R 组间差异完全消失 ($t = 0.015$, $p = 0.988$)，两者均达到 96.7% 的高准确率。这说明 Cross-Encoder 在精排阶段具有极强的纠错能力，能够“重置”粗排阶段的细微差异，使最终结果收敛至系统最优。三次重复实验显示准确率标准差 $< 1.7\%$ ，证明结果稳定可靠。

5. 讨论

实验结果引发了关于技术选型边界、模型架构差异及工程可行性的三个层面讨论。

CR 的有限改进与类型相关性。 与 Anthropic 原始报告相比（CR 降低检索失败率 49%），本文 CR 的效果明显较弱。Anthropic 依赖 Claude 等百亿参数级模型生成上下文，而本文使用 Gemma-3-12B。容量与指令遵循能力的差距导致了质量差异：小模型倾向生成高层次抽象（如“第三章 物资保障”）而非保留关键细节（如“冲锋舟 20 艘”）。虽然整体上 CR 相对 Baseline 仍有 3.3% 的改进，但这一改进不均匀分布于三类查询——数值查询获得显著提升（+10%），而复杂的实体列表和流程描述查询未见改善。这表明小模型上下文生成的有效性高度依赖内容结构：对信息密度低、结构简洁的数值查询有帮助，但对信息密度高、需要精确细节的列表型和流程型查询可能引入噪声。实际部署中，应基于具体应用场景的查询类型特征，谨慎评估 CR 的实际收益——包括上下文生成的计算成本与结果改进的实际价值。

Cross-Encoder 的鲁棒性来源。 重排序能够抵消 CR 噪声的根本原因在于架构差异。向量检索的双塔模型分别编码查询与文档，再计算余弦相似度，无法建模两者之间的深层交互。Cross-Encoder 则将查询与文档拼接后联合编码，全注意力机制可直接对齐“超汛限水位”与“开闸泄洪”等语义关联，即使文档前缀含有噪声上下文，模型仍可聚焦关键内容。消融实验中 B+R 与 CR+R 完全无差异的结果进一步佐证：重排序阶段对粗排输入具有“容错”能力，其精排质量主要取决于 Cross-Encoder 自身的建模能力而非上游信号。代价方面，实测重排序增加了约 **2.44 秒** 的额外计算开销，但这将检索准确率推至 **96.7%**，在防洪应急决策对准确性要求极高的场景下，该时间成本完全在可接受范围内。

KG 路线的瓶颈与出路。 知识图谱在本次实验中的表现揭示了两个层面的问题：一是抽取质量——即便使用 OneKE-13B 这一专用指令模型，在缺乏领域 Schema 约束时，面对水利预案的复杂表格与嵌套条款，其实体关系召回率**严重不足**，导致关键的数值型信息（时限、数量、标准）大量丢失；二是评分机制——现有 RAG 框架倾向于对图检索命中的节点赋予默认高分，掩盖了实际内容相关性不足的问题。KG 路线的改进方向包括：引入领域专家设计的严格 Schema、采用人工标注 + 主动学习的混合构建策略。在无上述条件的情况下，通用 KG 方案的工程可行性较低。

工程部署建议。 综合准确率、响应时间与实现复杂度，本文推荐 **Baseline + Reranker (B+R)** 作为水利行业检索问答系统的首选方案：准确率 **96.7%**，检索链路延迟控制在 **2.5 秒** 左右，技术栈全部基于开源模型（BGE 嵌入、BGE 重排序、Gemma-3 问答），本地部署无需商用 API。关于 CR 的使用决策需更加细致：尽管 CR 在整体上相对 Baseline 有 3.3% 改进且统计显著，但改进主要集中于数值查询（+10%），复杂实体和流程查询无改进。因此，若应用场景以数值查询为主，可考虑 CR；若查询多为实体列表与流程描述，CR 的增益有限而预处理成本增加。在任何情况下，引入重排序都能获得显著收益（准确率统一提升至 **96.7%**），且重排序的改进与粗排策略无关，具有通用性。不推荐在无标注条件下使用 KG 路线，其实际收益远低于向量检索方案。

6. 结论

本文面向水利防洪预案应急知识查询场景，在真实语料（6 份核心文档、1080 个语义切片）与 30 个业务测试题上，系统比较了上下文增强检索（Contextual Retrieval, CR）、知识图谱（KG）与 Cross-Encoder 重排序三类 RAG 增强方法。

2×2 消融实验表明：(1) **CR 的改进具有显著的不均匀性**。在本地小模型条件下，CR 仅呈现有限的改进（整体准确率提升 3.3%），其增益主要集中于**数值类查询**（+10%），而在复杂的实体与流程类问题中未观察到显著提升；(2) **重排序的决定性作用**。引入 Cross-Encoder 重排序能够有效消除粗排阶段的噪声与不均匀性，将系统准确率稳定提升至 **96.7%**（ $p < 0.001$ ）；(3) **通用 KG 的局限性**。知识图谱在缺乏领域 Schema 约束与人工标注的条件下，实体关系抽取质量不足，无法满足实际应用要求。

综合实验结果，本文推荐 **Baseline + Reranker** 作为水利行业低成本、高可靠检索问答系统的通用部署方案；对于查询特征明确为数值型的特定场景，可酌情结合 CR 以获取边际收益。未来工作将进一步探索自适应上下文生成机制、领域专用知识图谱的自动化构建方法，以及在更多水利业务场景（如水库调度、灌溉管理）中的扩展验证。

参考文献

- [1] 杨阳蕊, 朱亚萍, 刘雪梅, 陈思思, 李慧敏. 水利工程文本中抢险实体和关系的智能分析与提取[J]. 水利学报, 2023, 54(7): 818-828.
- [2] 杨阳蕊, 朱亚萍, 陈思思, 刘雪梅, 李慧敏. 融合群体智能策略的 AI 链在大坝防汛抢险知识推理中的应用[J]. 水利学报, 2023, 54(9): 1122-1132.
- [3] 杨阳蕊, 潘世峰, 刘雪梅, 马威, 冯岭. 多模态知识图谱与大模型协同的水利工程风险应对决策推荐[J]. 水利学报, 2025, 56(4): 519-530.
- [4] 杨阳蕊, 董方宁, 王鹏斐, 菅朋朋, 李海昆. 基于大语言模型的水利工程运行管理质量概念模型及知识图谱自动化构建[J]. 水利学报, 2025, 56(5): 634-645.
- [5] Pan S, Luo L, Wang Y, Chen C, Wang J, Wu X. Unifying Large Language Models and Knowledge Graphs: A Roadmap[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(7): 3580-3599.
- [6] Wu J, Gu B, Zhou R, Xie K, Snyder D, Jiang Y, Carducci V, Wyss R, Desai R J, Alsentzer E, Celi L A, Rodman A, Schneeweiss S, Chen J H, Romero-Brufau S, Lin K J, Yang J. BRIDGE: Benchmarking Large Language Models for Understanding Real-world Clinical Practice Text[EB/OL].
- [7] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[C]//Advances in Neural Information Processing Systems. 2020.
- [8] Anthropic. Introducing Contextual Retrieval[R/OL]. 2024-09-19.
- [9] Nogueira R, Cho K. Passage Re-ranking with BERT[EB/OL]. arXiv:1901.04085, 2019.
- [10] Zhu H, Chen Y, Xie R, et al. OneKE: A Unified Knowledge Extraction Framework[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics. 2023.
- [11] Xiao S, Liu Z, Zhang P, et al. C-Pack: Packaged Resources to Advance General Chinese Embedding[EB/OL]. arXiv:2309.07597, 2023.
- [12] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.

[13] Glass M, Rossiello G, Chowdhury M, et al. Re2G: Retrieve, Rerank, Generate[C]//NAACL 2022. 2022: 2701-2715.

[14] Zhu Y, Yuan H, Wang S, et al. Large Language Models for Information Retrieval: A Survey[EB/OL]. arXiv:2308.07107, 2023.

附录

All code and data used in this study are available at the GitHub repository: <https://github.com/rocee2692/contextual-retrieval-by-anthropic>
Reproducibility information is provided in the README file.